

HTML小实验：用代码分析HTML标准

2019-04-11 winter

《重学前端》

课程介绍 >



讲述：winter

时长 07:51 大小 7.20M



你好，我是 winter。

前面的课程中，我们已经讲解了大部分的 HTML 标签。

然而，为了突出重点，我们还是会忽略一些标签类型。比如表单类标签和表格类标签，我认为只有少数前端工程师用过，比如我在整个手机淘宝的工作生涯中，一次表格类标签都没有用到，表单类则只用过 input，也只有几次。


那么，剩下的标签我们怎么样去了解它们呢？当然是查阅 HTML 标准。

由于阅读标准有一定门槛，需要了解一些机制，这节课，我为你设计了一个小实验，用 JavaScript 代码去抽取标准中我们需要的信息。



HTML 标准

我们采用 WHATWG 的 living standard 标准，我们先来看看标准是如何描述一个标签的，这里我们看到，有下面这些内容。

 复制代码

```
1 Categories:
2   Flow content.
3   Phrasing content.
4   Embedded content.
5   If the element has a controls attribute: Interactive content.
6   Palpable content.
7 Contexts in which this element can be used:
8   Where embedded content is expected.
9 Content model:
10  If the element has a src attribute: zero or more track elements, then transpa
11  If the element does not have a src attribute: zero or more source elements, t
12 Tag omission in text/html:
13   Neither tag is omissible.
14 Content attributes:
15   Global attributes
16   src – Address of the resource
17   crossorigin – How the element handles crossorigin requests
18   poster – Poster frame to show prior to video playback
19   preload – Hints how much buffering the media resource will likely need
20   autoplay – Hint that the media resource can be started automatically when the
21   playsinline – Encourage the user agent to display video content within the el
22   loop – Whether to loop the media resource
23   muted – Whether to mute the media resource by default
24   controls – Show user agent controls
25   width – Horizontal dimension
26   height – Vertical dimension
27 DOM interface:
28   [Exposed=Window, HTMLConstructor]
29   interface HTMLVideoElement : HTMLMediaElement {
30     [CEReactions] attribute unsigned long width;
31     [CEReactions] attribute unsigned long height;
32     readonly attribute unsigned long videoWidth;
33     readonly attribute unsigned long videoHeight;
34     [CEReactions] attribute USVString poster;
35     [CEReactions] attribute boolean playsInline;
36   };
```

我们看到，这里的描述分为 6 个部分，有下面这些内容。

- Categories：标签所属分类。
- Contexts in which this element can be used：标签能够用在哪里。



- Content model: 标签内容模型。
- Tag omission in text/html: 标签是否可以省略。
- Content attributes: 内容属性。
- DOM interface: 用 WebIDL 定义的元素类型接口。

这一节课，我们关注一下 Categories、Contexts in which this element can be used、Content model 这几个部分。我会带你从标准中抓取数据，做一个小工具，用来检查 X 标签是否能放入 Y 标签内。

代码角度分析 HTML 标准

HTML 标准描述用词非常的严谨，这给我们抓取数据带来了巨大的方便，首先，我们打开单页面版 HTML 标准：

- <https://html.spec.whatwg.org/>

在这个页面上，我们执行一下以下代码：

 复制代码

```
1 Array.prototype.map.call(document.querySelectorAll(".element"), e=>e.innerText);
```

这样我们就得到了所有元素的定义了，现在有 107 个元素。

不过，比较尴尬的是，这些文本中并不包含元素名，我们只好从 id 属性中获取，最后代码类似这样：


 复制代码

```
1 var elementDefinitions = Array.prototype.map.call(document.querySelectorAll(".ele
2   text:e.innerText,
3   name:e.childNodes[0].childNodes[0].id.match(/the\-([\s\S])\-\element:/)?RegExp.
```



接下来我们用代码理解一下这些文本。首先我们来分析一下这些文本，它分成了 6 个部分，而且顺序非常固定，这样，我们可以用 JavaScript 的正则表达式匹配来拆分六个字段。


我们这个小实验的目标是计算代码块中哪些包含关系。因此，我们使用 `categories` 和 `contentModel` 两个字段。

 复制代码

```
1 for(let defination of elementDefinations) {
2
3   console.log(defination.name + ":")
4   let categories = defination.text.match(/Categories:\n([\s\S])\nContexts in whi
5   for(let category of categories) {
6     console.log(category);
7   }
8
9
10  /*
11   let contentModel = defination.text.match(/Content model:\n([\s\S])\nTag omissi
12   for(let line of contentModel)
13     console.log(line);
14  */
15 }
```

接下来我们来处理 `category`。

首先 `category` 的写法中，最基本的就是直接描述了 `category` 的句子，我们把这些不带任何条件的 `category` 先保存起来，然后打印出来其它的描述看看：

 复制代码

```
1 for(let defination of elementDefinations) {
2
3   //console.log(defination.name + ":")
4   let categories = defination.text.match(/Categories:\n([\s\S])\nContexts in whi
5   defination.categories = [];
6   for(let category of categories) {
7     if(category.match(/^([ ]+) content.//))
8       defination.categories.push(RegExp.$1);
9     else
10      console.log(category)
11   }
12
13
14  /*
15   let contentModel = defination.text.match(/Content model:\n([\s\S])\nTag omissi
16   for(let line of contentModel)
17     console.log(line);
18  */
19 }
```



这里我们要处理的第一个逻辑是带 if 的情况。

然后我们来看看剩下的情况：

 复制代码

```
1  None.
2  Sectioning root.
3  None.
4  Sectioning root.
5  None.
6  Form-associated element.
7  Listed and submittable form-associated element.
8  None.
9  Sectioning root.
10 None.
11 If the type attribute is not in the Hidden state: Listed, labelable, submittable
12 If the type attribute is in the Hidden state: Listed, submittable, resettable, a
13 Listed, labelable, submittable, and autocapitalize-inheriting form-associated el
14 Listed, labelable, submittable, resettable, and autocapitalize-inheriting form-a
15 None.
16 Listed, labelable, submittable, resettable, and autocapitalize-inheriting form-a
17 Listed, labelable, resettable, and autocapitalize-inheriting form-associated ele
18 Labelable element.
19 Sectioning root.
20 Listed and autocapitalize-inheriting form-associated element.
21 None.
22 Sectioning root.
23 None.
24 Sectioning root.
25 Script-supporting element.
```


这里出现了几个概念：

- None
- Sectioning root
- Form-associated element
- Labelable element
- Script-supporting element




如果我们真正完美地实现加微作x923719 备用QQ:2902839937就必须要在代码中加入正则表达式来解析这些规则，这里作为今天的课后问题，留给你自己完成。

接下来我们看看 Content Model，我们照例先处理掉最简单点的部分，就是带分类的内容模型：

 复制代码

```
1
2 for(let defination of elementDefinations) {
3
4   //console.log(defination.name + ":")
5   let categories = defination.text.match(/Categories:\n([\s\S]+)\nContexts in whi
6   defination.contentModel = [];
7   let contentModel = defination.text.match(/Content model:\n([\s\S]+)\nTag omissi
8   for(let line of contentModel)
9     if(line.match(/^([ ]+) content./))
10      defination.contentModel.push(RegExp.$1);
11   else
12     console.log(line)
13 }
14
```

好了，我们照例看看剩下了什么：

 复制代码

```
1 A head element followed by a body element.
2 If the document is an iframe srcdoc document or if title information is availabl
3 Otherwise: One or more elements of metadata content, of which exactly one is a t
4 Text that is not inter-element whitespace.
5 Nothing.
6 Text that gives a conformant style sheet.
7 One or more h1, h2, h3, h4, h5, h6 elements, optionally intermixed with script-s
8 Nothing.
9 Zero or more li and script-supporting elements.
10 Either: Zero or more groups each consisting of one or more dt elements followed
11 Or: One or more div elements, optionally intermixed with script-supporting eleme
12 Either: one figcaption element followed by flow content.
13 Or: flow content followed by one figcaption element.
14 Or: flow content.
15 If the element is a child of a dl element: one or more dt elements followed by o
16 If the element is not a child of a dl element: flow content.
17 Transparent, but there must be no interactive content or a element descendants.
18 See prose.
19 Text.
20 If the element has a datetime attribute: Phrasing content.
```



21 Otherwise, text that must match requirements described in prose below.
 22 Nothing.
 23 Transparent.
 24 Zero **or** more source elements, followed **by one** img element, optionally intermixed
 25 Nothing.
 26 Zero **or** more param elements, **then**, transparent.
 27 Nothing.
 28 If the element has a src attribute: zero **or** more track elements, **then** transparent
 29 If the element does **not** have a src attribute: zero **or** more source elements, **then**
 30 If the element has a src attribute: zero **or** more track elements, **then** transparent
 31 If the element does **not** have a src attribute: zero **or** more source elements, **then**
 32 Nothing.
 33 Transparent.
 34 Nothing.
 35 **In this order**: optionally a caption element, followed **by** zero **or** more colgroup e
 36 If the span attribute **is** present: Nothing.
 37 If the span attribute **is** absent: Zero **or** more col **and** template elements.
 38 Nothing.
 39 Zero **or** more tr **and** script-supporting elements.
 40 Zero **or** more td, th, **and** script-supporting elements.
 41 Nothing.
 42 Zero **or** more option, optgroup, **and** script-supporting elements.
 43 Either: phrasing content.
 44 **Or**: Zero **or** more option **and** script-supporting elements.
 45 Zero **or** more option **and** script-supporting elements.
 46 If the element has a label attribute **and** a **value** attribute: Nothing.
 47 If the element has a label attribute but **no value** attribute: Text.
 48 If the element has **no** label attribute **and is not** a child **of** a datalist element:
 49 If the element has **no** label attribute **and is** a child **of** a datalist element: Text
 50 Text.
 51 Optionally a legend element, followed **by** flow content.
 52 **One** summary element followed **by** flow content.
 53 Either: phrasing content.
 54 **Or**: **one** element **of** heading content.
 55 If there **is no** src attribute, depends **on** the **value of** the type attribute, but mu
 56 If there **is** a src attribute, the element must be either **empty or** contain **only** sc
 57 **When** scripting **is** disabled, **in** a head element: **in any order**, zero **or** more link e
 58 **When** scripting **is** disabled, **not in** a head element: transparent, but there must b
 59 Otherwise: text that conforms **to** the requirements given **in** the prose.
 60 Nothing (**for** clarification, see example).
 61 Transparent
 62 Transparent but **with no** interactive content descendants **except for** a elements

这有点复杂，我们还是把它做一些分类，首先我们过滤掉带 If 的情况、Text 和 Transparent。



复制代码


```
1 for(let defination of elementDefinations) {
2   //console.log(defination.name + ":")
```

```

3 let categories = definition.text.match(/Categories:\n([\s\S]+)\nContexts in whi
4 definition.contentModel = [];
5 let contentModel = definition.text.match(/Content model:\n([\s\S]+)\nTag omissi
6 for(let line of contentModel)
7   if(line.match(/([ ]+) content./))
8     definition.contentModel.push(RegExp.$1);
9   else if(line.match(/Nothing.|Transparent./));
10  else if(line.match(/^Text[\s\S]*.$/));
11  else
12    console.log(line)
13 }

```

这时候我们再来执行看看：

 复制代码

```

1 A head element followed by a body element.
2 One or more h1, h2, h3, h4, h5, h6 elements, optionally intermixed with script-su
3 Zero or more li and script-supporting elements.
4 Either: Zero or more groups each consisting of one or more dt elements followed b
5 Or: One or more div elements, optionally intermixed with script-supporting elemen
6 If the element is a child of a dl element: one or more dt elements followed by on
7 See prose.
8 Otherwise: Text, but must match requirements described in prose below.
9 Zero or more source elements, followed by one img element, optionally intermixed
10 Zero or more param elements, then, transparent.
11 If the element has a src attribute: zero or more track elements, then transparent
12 If the element does not have a src attribute: zero or more source elements, then
13 If the element has a src attribute: zero or more track elements, then transparent
14 If the element does not have a src attribute: zero or more source elements, then
15 In this order: optionally a caption element, followed by zero or more colgroup el
16 If the span attribute is absent: Zero or more col and template elements.
17 Zero or more tr and script-supporting elements.
18 Zero or more td, th, and script-supporting elements.
19 Zero or more option, optgroup, and script-supporting elements.
20 Or: Zero or more option and script-supporting elements.
21 Zero or more option and script-supporting elements.
22 If the element has a label attribute but no value attribute: Text.
23 If the element has no label attribute and is not a child of a datalist element: T
24 If the element has no label attribute and is a child of a datalist element: Text.
25 When scripting is disabled, in a head element: in any order, zero or more link el
26 When scripting is disabled, not in a head element: transparent, but there must be
27 Otherwise: text that conforms to the requirements given in the prose.

```



这下剩余的就少多了，我们可以看到，基本上剩下的都是直接描述可用的元素了，如果你愿意，还可以用代码进一步解析，不过如果是我的话，会选择手工把它们写成 JSON 了，毕竟只有三十多行文本。

好了，有了 contentModel 和 category，我们要检查某一元素是否可以作为另一元素的子元素，就可以判断一下两边是否匹配啦，首先，我们要做个索引：

 复制代码

```
1 var dictionary = Object.create(null);
2
3 for(let defination of elementDefinations) {
4     dictionary[defination.name] = defination;
5 }
6
```

然后我们编写一下我们的 check 函数：

 复制代码

```
1 function check(parent, child) {
2     for(let category of child.categories)
3         if(parent.contentModel.categories.contains(category))
4             return true;
5     if(parent.contentModel.names.contains(child.name))
6         return true;
7     return false;
8 }
9
```

总结

这一节课，我们完成了一个小实验：利用工具分析 Web 标准文本，来获得元素的信息。

通过这个实验，我希望能够传递一种思路，代码能够帮助我们从 Web 标准中挖掘出来很多想要的信息，编写代码的过程，也是更深入理解标准的契机。

我们前面的课程中把元素分成了几类来讲解，但是这些分类只能大概地覆盖所有的标签，我设置课程的目标也是讲解标签背后的知识，而非每一种标签的细节。具体每一种标签的属性和细节，可以留给大家自己去整理。

这一节课的产出，则是“绝对完整的标签列表”，也是我学习和阅读标准的小技巧，通过代码我们可以从不同的侧面分析标准的内容，挖掘需要注意的点，这是一种非常好的学习方法。



更多资源加微信x923713 备用QQ: 2902839937

分享给需要的人, Tai订阅超级会员, 你将得 50 元

Ta单独购买本课程, 你将得 20 元

生成海报并分享

赞 9 提建议

© 版权归极客邦科技所有, 未经许可不得传播售卖。页面已增加防盗追踪, 如有侵权极客邦将依法追究其法律责任。

上一篇 HTML替换型元素: 为什么link一个CSS要用href, 而引入js要用src呢?

下一篇 CSS Flex排版: 为什么垂直居中这么难?

学习推荐

JVM + NIO + Spring

各大厂面试题及知识点详解

限时免费



精选留言 (10)

写留言



阿成

2019-04-14

这种“通过简单的文本分析, 快速提炼出自己感兴趣的部分”的方法是非常值得借鉴的, 我平时也会用这种方法去网页中做一些快速的统计和信息筛选。

不过, 通过这样的文本分析去完成一个“检查一个元素是否能够放置在另一个元素内部”的小



程序还是有点把问题复杂化的感觉（尽管这个过程中也可以锻炼一些能力），况且文档是会更新的，说不定有一天那些check分支就hold不住新的case了。

在我看来，如果想知道A元素是否可以放在B元素中，只要把所有元素的categories和content Model提取出来，筛选出A元素的categories和B元素的contentModel，再去阅读比较就可以了（当然你还要对标准中的一些术语有所了解，所幸的是这些术语都有超链接指向定义，所以还是比较方便的 $\forall (\geq \nabla \leq *)o$ ）。



18



一步

2019-04-29

老师 有个疑问： WHATWG 和 W3C 标准以哪个为准，这两个标准有什么区别？是不是相互不认可的



7



前端男孩

2020-02-16

为什么我去网页控制台上Console出不来呢？



3



会飞的大猫

2019-04-11

Winter，刚看完文章，就在淘宝技术节视频看到了你持相机和大家自拍的图片



1



Clors

2020-09-04

我提出一个场景，如果vw布局网页，不使用iframe如何做到限制最大大小？



1



Change

2020-03-07

本想实践一下这个实验，奈何<https://html.spec.whatwg.org/>链接打不开是什么情况？

共 1 条评论 >

1



爱学习的大叔

2019-06-02

没太看懂，好多语法基于这个页面<https://html.spec.whatwg.org/>





更多资源加微信x923713👉备用QQ: 2902839937



away

2019-04-30

@一步 WHATWG 和 W3C 标准若有不同，一般以 WHATWG 为准



嗨海海

2019-04-12

学不到，有因果关系，工作实际需要吗？



被雨水过滤的空气

2019-04-11

学习了

